

室温フォトニック量子計算における相関ノイズデコーダの階層的評価：スケール不変性の検証から残差減算・GNN デコーダまで

著者: 谷 智栄 (Tomohiro Tani)

独立研究者

概要

室温連続変数 (CV) フォトニック量子コンピュータでは、共通ポンプレーザーに起因するモード間相関ノイズが耐故障性を脅かす。本研究では、相関ノイズに対する 4 つのデコーダ戦略を体系的に評価し、デコーダの階層構造を確立する。(1) V_{eff} 再校正 MWPM はスケール不変性により vanilla と同値であることを 170,000 ショットで数値的に検証した (全ショット判定一致)。(2) 残差減算 MWPM は共通モードを残差平均から推定・除去することでスケール不変性を迂回し、 $d=5$ で最大 41.8 倍 (95% CI: [14.0, 125])、 $d=7$ で 19.0 倍の改善を達成する。この手法は通信工学における共通モード除去 [9] の量子誤り訂正への適用である。(3) GNN デコーダ (4,033 パラメータ; AlphaQubit[10] の 10M+ パラメータに対し約 2,500 分の 1) は相関構造をグラフ畳み込みで学習し、 $d=5$ で最大 33.4 倍 (95% CI: [12.3, 90.9]) を達成する。(4) 混合 ρ 訓練の単一 GNN モデルが訓練分布外 $\rho=0.20$ で $d=7$ において 20.8 倍の優位を維持する。 $\rho=0$ (相関なし) では GNN は MWPM に対し $d=3$ で 0.60 倍、 $d=5$ で 0.75 倍と劣位であり、残差減算も $d=3$ で 0.84 倍に悪化する——相関デコーダは相関の存在を前提とし、独立ノイズ下では性能を損なう。 $d=3,5,7$ の 3 距離にわたる統一パラメータ実験 (総計約 920,000 ショット、seed=42 で再現可能) により、デコーダ階層を実証する。

I. 序論

A. 相関ノイズ問題

室温 CV フォトニック量子コンピュータでは、2 つの PPLN OPA が共通ポンプレーザーを共有するため、ポンプの相対強度ノイズ (RIN) がモード間に相関変位ノイズを導入する [6,8]。MWPM デコーダ [3] は独立ノイズを前提とするため、この相関は耐故障性を直接劣化させる。

先行研究 [1] は CV 系の正しいノイズモデル (現象論的、soft-info MWPM) を同定したが、相関ノイズ下でのデコーダ最適化は未解決であった。ニューラルデコーダ [5,10,11,13] およびコード設計の進展 [12] が DV 系で有望な結果を示す一方、CV フォトニック系の相関ノイズに対する体系的評価は行われていない。

B. 4 つの疑問

1. MWPM の重みを相関に応じて再校正すれば改善するか？
2. 残差から共通モードを直接除去すれば改善するか？
3. ML デコーダは相関構造を学習できるか？
4. 単一モデルで未知の相関レベルに適応できるか？

C. 本研究の貢献

4 つのデコーダを統一パラメータ ($d=3,5,7$, seed=42) で体系的に比較し、以下を実証する：

1. **No-go result: V_{eff} 適応の原理的不可能性:** V_{eff} 再校正 MWPM は 170,000 ショットで全ショット vanilla と判定一致。一様なノイズスケーリングに対する MWPM 適応は原理的に無効であり、この盲点を埋める
2. **残差減算 MWPM の提案:** 通信工学の共通モード除去 [9] を CV-QEC に適用。d=5 で最大 41.8 倍改善
3. **GNN の距離スケーリング:** d=3 $\rightarrow$ 5 $\rightarrow$ 7 で優位が単調に拡大
4. **Hardware-adaptive GNN:** mixed- ρ 単一モデルが OOD $\rho=0.20$ で d=7 において 20.8 倍の優位を維持

II. 物理モデル

A. GKP 変位ノイズ

GKP 符号 [4] の実効ノイズ分散（ビームスプリッタモデル）：

$$V_{\text{eff}} = \eta \cdot V_{\text{sqz}} + (1 - \eta) + V_{\text{nl}}$$

ここで V_{eff} はショットノイズ単位 (SNU; 真空ノイズ = 1 SNU) の実効ノイズ分散、 η は全光学透過率、 $V_{\text{sqz}} = 10^{-(\sigma_{\text{gen}}/10)}$ はスクイーズド状態分散、 V_{nl} は電子ノイズ等の非損失ノイズ源。 $\sigma_{\text{eff}} = -10 \log_{10}(V_{\text{eff}})$ [dB] は実効スクイージングレベルと呼ばれ、 V_{eff} が小さいほど高品質な GKP 量子ビットを意味する。

本研究では Phase 1 動作点を使用する： $\sigma_{\text{eff}} = 8.5$ dB ($\sigma_{\text{gen}} = 13$ dB、 $L = 0.39$ dB、 $V_{\text{nl}} = 0.010$ SNU 込み)、 $V_{\text{eff}} = 0.1417$ SNU、 $p_{\text{phys}} = 9.28 \times 10^{-3}$ (付録 B 参照)。

B. 相関ノイズモデル

共通ポンプ RIN により、異なるモードの変位誤りに相関が生じる。相関係数 ρ のもとで、モード対 (i, j) の変位は

$$(\delta_i, \delta_j) \sim N(0, V_{\text{eff}} \times [[1, \rho], [\rho, 1]])$$

実装: $\delta_i = \sqrt{V_{\text{eff}}} \times (\sqrt{(1 - \rho)} \cdot z_i + \sqrt{\rho} \cdot z_{\text{common}})$ 、ここで $z_i, z_{\text{common}} \sim N(0, 1)$ は独立標準正規変量。

ρ とハードウェアパラメータの対応を以下の表に示す。これらは共通ポンプ RIN、WDM チャネル間アイソレーション、OPA 利得帯域幅、検出帯域幅の複合効果から生じる桁感の目安であり、厳密な 1 対 1 対応ではない。詳細な導出はシステム設計に依存するため、本研究では ρ をモデルパラメータとして独立に掃引する。

ρ	物理的条件	典型的な RIN・アイソレーション水準
0.003	設計仕様	RIN – 150 dB/Hz、WDM isolation 30 dB
0.03	仕様上限	RIN – 130 dB/Hz、WDM isolation 18 dB
0.08	劣化条件 ($\approx \rho^*$)	RIN – 127 dB/Hz、WDM isolation 14 dB
0.10	顕著な相関	RIN – 125 dB/Hz
0.20	FT 境界 (OOD 評価用)	システムレベル障害

III. 方法

A. シミュレーション基盤

Stim 1.15.0[2] による rotated surface code 検出器エラーモデル (DEM) 生成、PyMatching 2.3.1[3] による MWPM デコーディング。GKP 変位ノイズと相関ノイズをカスタム実装し、DEM のエッジ構造上で GKP 残差とシンδροームを生成した。全実験 seed=42 で再現可能。コードは https://github.com/TomohiroTani28/Taros/tree/main/research/03_gnn-photonic-decoder で公開。

B. 統一パラメータ

d	DEM edges (全体/使用†)	検出器数	n_train	n_test	rounds	epochs
3	76 / 66	24	5,000	30,000	3	40
5	418 / 334	120	5,000	30,000	5	40
7	1,224 / 954	336	3,000	10,000	7	40

† Stim DEM の全エラーエントリ数 / `extract_graph()` が 1-detector・2-detector エラーのみを抽出した実使用エッジ数。本研究の全シミュレーションは後者 (66/334/954) を使用。

$\rho \in \{0.00, 0.03, 0.05, 0.08, 0.10, 0.15\}$ 。OOD 評価: $\rho = 0.20$ 。

C. 4つのデコーダ

1. **Vanilla soft-info MWPM:** GKP 残差から LLR 重み $w(r) = ((\sqrt{\pi} - |r|)^2 - |r|^2)/(2V_{\text{eff}})$ を計算し、エッジ重みとする。ベースライン
2. **V_{eff} 再校正 MWPM:** 残差の二次モーメントから V_{eff} をショットごとに推定 ($V^{\wedge} = \text{mean}(r^2)$) し、LLR を再計算
3. **残差減算 MWPM:** 全エッジの残差平均 $r^- = \text{mean}(r_j)$ を共通モード推定量として減算 ($r'_j = r_j - r^-$) 後、元の V_{eff} で LLR を再計算。通信工学における共通モード除去 [9] の CV-QEC 版
4. **GNN Lite:** 3 層 Graph Convolutional Network[14] (GCNConv、隠れ次元 32、LayerNorm、全 4,033 パラメータ; Google AlphaQubit[10] の 10M+パラメータに対し約 2,500 分の 1)。入力特徴: GKP 残差 r 、 $|r|$ 、LLR $w(r)$ の 3 次元。出力: MWPM に渡す修正エッジ重み (Softplus 活性化で正值保証)

D. GNN 訓練詳細

- **損失関数:** Binary cross-entropy。GNN の出力重み w からエッジごとのエラー確率 $p = \sigma(-w + 2)$ を計算し、真のエッジエラーとの BCE 損失を最小化
- **最適化:** AdamW (lr= 2×10^{-3} , weight_decay= 10^{-4}) + CosineAnnealingLR
- **Per- ρ 訓練:** 各 ρ 値で個別 GNN を訓練 (6 モデル/d)
- **Mixed- ρ 訓練:** $\rho \in \{0, 0.03, 0.05, 0.08, 0.10, 0.15\}$ の一様混合で単一 GNN を訓練し、全 ρ +OOD で評価
- **デバイス:** Apple Silicon MPS (PyTorch 2.5.1, torch_geometric)

E. 統計的報告方法

各デコーダの p_L に対する 95%信頼区間は Wilson score interval で計算した。比 (改善率) の 95% 信頼区間は、分子・分母の Wilson 区間端点から保守的に構成した (ratio CI = $[p_1_lo/p_2_hi, p_1$

$_{\text{hi}/p_2}_{\text{lo}}]$ 。エラー数0の条件ではポアソン分布の95%上界 $3/n_{\text{test}}$ (rule of three) を用い、改善下界を「 $\geq X\times$ 」と報告した。低カウント ($k \leq 5$) の比 CI は幅が広く (例: $4/30,000$ vs $167/30,000$ で $\text{CI} = [14.0, 125]$)、点推定値は参考として精密な比率推定にはより大きな n_{test} が必要である。

IV. 結果

A. スケール不変性の数値的検証 (Decoder 2)

V_{eff} 再校正 MWPM と vanilla MWPM を $d=3,5,7 \times 6 \rho = 18$ 条件、計 170,000 ショットで比較した。

全 18 条件、全 170,000 ショットで vanilla と判定が完全一致 (agree = 100%)。

これはスケール不変性の帰結である (付録 A 参照)。LLR $w(r, V) \propto 1/V$ であるため、 V 変化は全エッジを同一スカラーでスケールし、MWPM の最小重みマッチングは不変。 V_{eff} 推定の精度に関わらず、一様な V_{eff} 変化に対する MWPM 適応は不可能である。

B. 残差減算 MWPM (Decoder 3)

4-Decoder Comparison: p_L vs Correlation ρ




図 1. 4 デコーダの p_L vs 相関係数 ρ 。 $d=5$ (左) と $d=7$ (右)。95%信頼区間付き。エラー 0 の点は 95%上界を下向き矢印で表示。残差減算 (橙) と GNN (青) が ρ 増加とともに vanilla MWPM (赤) から乖離する。

共通モード除去 [9] の CV-QEC 版として、残差平均による推定・除去を適用した。各エッジの残差が非一様に修正されるため、スケール不変性を迂回する (付録 A 参照)。

表 I. 残差減算 MWPM vs vanilla MWPM。95% Wilson 信頼区間付き。

ρ	$d=3$ van/res (err/30K)	改善 [95% CI]	$d=5$ van/res (err/30K)	改善 [95% CI]
0.00	81 / 96	$0.84\times [0.63, 1.13]$	9 / 9	$1.00\times [0.33, 3.00]$

ρ	d=3 van/res (err/30K)	改善 [95% CI]	d=5 van/res (err/30K)	改善 [95% CI]
0.03	89 / 73	1.22× [0.89, 1.67]	22 / 5	4.40× [1.2, 15.6]
0.05	110 / 70	1.57× [1.16, 2.13]	24 / 7	3.43× [1.1, 10.5]
0.08	128 / 55	2.33× [1.69, 3.20]	36 / 7	5.14× [1.8, 14.7]
0.10	135 / 38	3.55× [2.47, 5.12]	64 / 3	21.3× [5.7, 80.1]
0.15	224 / 35	6.40× [4.47, 9.16]	167 / 4	41.8× [14.0, 125]

d=7 (n_test=10,000) : $\rho=0.03\sim 0.10$ で残差減算エラー 0 ($p_L \leq 3.0 \times 10^{-4}$ 、95%ポアソン上界)。 $\rho=0.15$ で vanilla 38 $\rightarrow$ 残差減算 2 (19.0×、95% CI: [3.8, 95.0])。

3つの発見：

(i) $\rho=0$ で悪化する。d=3 $\rho=0.00$ で 0.84 倍 (95% CI が 1.0 を含むため統計的有意性は限定的だが、方向は一貫)。相関がない場合、残差平均は純粋なノイズであり、減算は残差にノイズを追加する。残差減算は相関の存在を前提とし、 $\rho=0$ では使用すべきでない。

(ii) 高 d ほど改善が大きい。d=3: 6.4 倍、d=5: 41.8 倍 (@ $\rho=0.15$)。実使用 DEM エッジ数の増加 (d=3: 66、d=5: 334、d=7: 954) に伴い、共通モードの推定精度が向上するためである (標準誤差 $\propto 1/\sqrt{N_{\text{edges}}}$)。

(iii) 共通モードモデルを仮定している。実際の相関構造が非共通モード (空間的不均一、時変など) の場合、推定精度が低下し性能が劣化する可能性がある。

C. Per- ρ 訓練 GNN (Decoder 4)

表 II. Per- ρ GNN vs vanilla MWPM。95% CI 付き。表記: vanilla err / GNN err。

ρ	d=3 (err/30K)	改善 [95% CI]	d=5 (err/30K)	改善 [95% CI]
0.00	81 / 136	0.60× [0.45, 0.79]	9 / 12	0.75× [0.28, 2.03]
0.03	89 / 139	0.64× [0.49, 0.84]	22 / 15	1.47× [0.74, 2.90]
0.05	110 / 118	0.93× [0.72, 1.21]	24 / 12	2.00× [0.97, 4.10]
0.08	128 / 114	1.12× [0.87, 1.45]	36 / 10	3.60× [1.77, 7.32]
0.10	135 / 62	2.18× [1.60, 2.96]	64 / 4	16.0× [5.84, 43.8]
0.15	224 / 50	4.48× [3.27, 6.13]	167 / 5	33.4× [12.3, 90.9]

$d=7$ ($n_{\text{test}}=10,000$) : $\rho=0.10$ で $19 / 1$ ($19.0\times$, 95% CI: [2.1, 168])。 $\rho=0.03\sim 0.08$ および $\rho=0.15$ で GNN エラー 0 ($p_L \leq 3.0\times 10^{-4}$, 95%ポアソン上界)。




図 2. GNN/MWPM 優位比の符号距離依存性。3 つの ρ 値で単調増加を確認。

距離スケール: $\rho=0.10$ で $d=3$: $2.18\times$, $d=5$: $16.0\times$, $d=7$: $19.0\times$ 。GNN 優位は符号距離とともに単調増加する。

$\rho=0$ での劣位: $d=3$ で $0.60\times$, $d=5$ で $0.75\times$ 。独立ノイズ下では MWPM が (局所的に) 最適に近い
ため、GNN のグラフ畳み込みによる「相関学習」がノイズとして作用する。GNN は万能ではなく、
相関がない環境では vanilla MWPM が最適選択である。

D. GNN vs 残差減算の直接比較

表 III. $d=5$ ($n_{\text{test}}=30,000$) での 3 デコーダ比較。同じ性能水準で工学的に最も単純なデコーダを「最良」とする。

ρ	Vanilla (err)	残差減算 (err)	GNN (err)	推奨	理由
0.00	9	9	12	Vanilla	残差減算=同 等、GNN 劣位
0.03	22	5	15	残差減算	$4.40\times$ vs $1.47\times$ 。追加 HW コスト ゼロ

ρ	Vanilla (err)	残差減算 (err)	GNN (err)	推奨	理由
0.05	24	7	12	残差減算	3.43× vs 2.00×。ソフトウェア変更のみ
0.08	36	7	10	残差減算	5.14× vs 3.60×
0.10	64	3	4	残差減算	21.3× vs 16.0×
0.15	167	4	5	残差減算	41.8× vs 33.4×

$d=5$ では共通モード型相関の全 $\rho > 0$ で残差減算が GNN を上回る。334 エッジ（実使用数）の平均による共通モード推定が極めて精確であり、かつ実装コストがゼロ（ソフトウェア変更のみ、FPGA 追加リソース：加算器+除算器）であるため、「同じ性能水準ならより単純な手法が勝つ」という工学的原則に従い、共通モード型相関では Decoder 3 を推奨する。

ただし Decoder 3 には 2 つの根本的制約がある：1. $\rho = 0$ で悪化 — 相関ゼロ時は vanilla に劣る。 ρ が未知の場合、 ρ 推定器（CUSUM 等）との組み合わせが必要 2. 共通モードモデル依存 — 空間的に不均一な相関（WDM チャンネル別 ρ 、マクロノード 4 モード構造由来の相関）には対応不可

これらの制約が該当する場合に GNN（Decoder 4）が優位となる。

E. Mixed- ρ GNN : Hardware-Adaptive デコーディング




図 3. Mixed- ρ GNN（単一モデル）の改善比。OOD $\rho = 0.20$ を含む。

ρ 混合訓練の単一 GNN モデルを全 ρ + OOD $\rho=0.20$ で評価した。

表 IV. Mixed- ρ GNN (単一モデル、再訓練不要)。表記: MWPM err / MixGNN err。

ρ	d=3 (err/30K)	比率	d=5 (err/30K)	比率	d=7 (err/10K)	比率
0.00	91 / 135	0.67×	6 / 23	0.26×	2 / 1	2.0×
0.03	103 / 111	0.93×	15 / 13	1.15×	0 / 0	—
0.08	141 / 101	1.40×	35 / 8	4.38×	9 / 0	>=3.0×
0.10	139 / 86	1.62×	62 / 7	8.86×	23 / 0	>=7.7×
0.15	242 / 103	2.35×	159 / 13	12.2×	45 / 1	45.0× [5.9, 341]
0.20 (OOD)	337 / 109	3.09×	248 / 25	9.92×	83 / 4	20.8× [6.5, 66.1]

(d=7 GNN エラー 0 の条件: 改善下界を 95%ポアソン上界 $3/n_{\text{test}}$ から計算し「 $\geq X\times$ 」と表記)

OOD $\rho=0.20$ での残差減算との比較 (追加実験) :

d	Vanilla (err)	残差減算 OOD	Mixed- ρ GNN OOD	残差減算改善	GNN 改善
3	310/30K	38	109	8.2×	3.1×
5	276/30K	12	25	23.0×	9.9×
7	99/10K	4	4	24.8×	20.8×

残差減算は OOD $\rho=0.20$ でも GNN を上回る (d=3: 8.2× vs 3.1×, d=5: 23.0× vs 9.9×)。d=7 では同等 (24.8× vs 20.8×)。共通モード型相関であれば、 ρ が訓練分布外であっても残差減算の原理 (残差平均による共通モード推定) は物理的に有効であり、ML 学習に依存しない。

ただしこの結果は、相関構造が共通モードモデルに従う場合に限定される。実運用で相関構造が変化する環境 (例: WDM チャネル劣化による空間的不均一相関) では Mixed- ρ GNN が優位となる可能性がある。

Mixed- ρ GNN の $\rho=0$ での振る舞い: d=5 で 0.26× (6 → 23 エラー) に悪化するが、これは per- ρ GNN の 0.75× よりさらに大きい劣化である。混合訓練では低 ρ 領域の学習が相対的に不足するためと考えられる。 $\rho=0$ での動作が想定される環境では vanilla MWPM が最適であり、Mixed- ρ GNN の適用は $\rho>0$ が確認された場合に限るべきである。

V. 議論

A. デコーダの階層構造

本研究で確立されたデコーダ階層:

Decoder 1: Vanilla MWPM — ベースライン。 $\rho=0$ で最適
↓ スケール不変性 (agree=100%で検証)

Decoder 2: V_eff 再校正 MWPM — vanilla と同値。改善不可能

↓ 残差の非一様修正でスケール不変性を迂回

Decoder 3: 残差減算 MWPM — $\rho > 0$ 、共通モード型相関で最強。実装コストゼロ

↓ モデルフリー学習で相関構造に依存しない

Decoder 4: GNN Lite — ρ 未知・変動時の hardware-adaptive 最適

各段階で「より複雑なデコーダが必要になる物理的条件」が明確であり、実装においては最も単純な十分条件を選択すべきである。

B. 残差減算の文献的位置づけ

残差減算による共通モード除去は、通信工学における干渉除去技術 [9]、特に MIMO 受信機の共通位相誤差 (CPE) 推定 [15] と同じ原理に基づく。OFDM システムでは全サブキャリアの位相回転の平均から共通位相誤差を推定し除去する。本研究の残差減算はこれを GKP 残差に適用したものであり、DEM エッジが多いほど (サブキャリア数が多いほど) 推定精度が向上する点も共通する。

C. 距離スケージングの物理的理由

$d=3,5,7$ の 3 点で、全デコーダの改善が符号距離とともに単調増加する。

- **残差減算:** 実使用 DEM エッジ数が $66 \rightarrow 334 \rightarrow 954$ と増加。共通モード推定量 $r^- = (1/N) \sum r_j$ の標準誤差は $\sigma/\sqrt{N}$ に比例して減少。 $d=7$ で 954 エッジの平均は正確な共通モード推定を提供する
- **GNN:** 3 層 GCN の受容野は 3 ホップ。 d 増加に伴いマッチンググラフが拡大し、長距離相関構造の活用可能範囲が広がる。また、訓練サンプルあたりの「相関エッジ対」数が $O(N^2)$ で増加し、相関構造の学習効率が向上する

D. スケール不変性の定理

LLR $w(r, V) = ((\sqrt{\pi} - |r|)^2 - |r|^2) / (2V)$ に対し、 $V \rightarrow V'$ の変更は全エッジに同一スカラー V/V' を乗じる。MWPM は $\arg \min_M \sum w_j$ であり、正定数倍に対して不変 (付録 A)。

残差減算はこの不変性を破る： $r_j \rightarrow r_j - r^-$ の操作は各エッジの r を非一様に修正し、 $|(r_j - r^-)| \neq c \cdot |r_j|$ であるため、LLR の相対関係が変化する。

E. 制限事項

1. **$d=7$ の統計:** $n_{\text{test}}=10,000$ で GNN エラー 0 が多数。これらの条件では 95%ポアソン上界 ($p_L \leq 3.0 \times 10^{-4}$) のみ報告可能。精密な比率推定には $n_{\text{test}} \geq 100,000$ が必要
2. **マクロノード固有相関:** 本研究の ρ はモデルパラメータとして導入。マクロノード BS 網の 4 モード構造 [6] に起因する固有相関は未モデル化
3. **GNN 推論レイテンシ:** $\sim 6\text{ms}/\text{shot}$ ($d=3$, Apple MPS) はリアルタイム QEC ($\sim 10\text{ns}/\text{cycle}$) に対して 10^6 倍遅い。FPGA/ASIC 実装によるリアルタイムデコーディング [16,17] が実運用には必須。AlphaQubit[10] は TPU 依存であり同様の課題を抱える
4. **$\rho=0$ での劣化:** GNN および残差減算は独立ノイズ下で vanilla MWPM に劣る。実運用では ρ 推定に基づくデコーダ切り替え機構が必要

VI. 結論

室温 CV フォトニック QEC における相関ノイズデコーダの 4 段階階層を確立した。

1. **No-go result: V_{eff} 再校正は原理的に無効。** 170,000 ショットで検証。MWPM のスケール不変性により、一様な V_{eff} 適応はデコード結果を変えない。この結果は「ノイズパラメータを正確に知ればデコーダが改善する」という直感的期待を否定し、相関ノイズ下で MWPM を改善するにはスケール不変性を迂回する手法（残差減算または ML）が必要であることを示す。
2. **残差減算 MWPM が共通モード型相関に最強。** $d=5$ で最大 41.8 倍 (95% CI: [14.0, 125])、 $d=7$ で 19.0 倍。実装コストゼロ。ただし $\rho=0$ では悪化 ($d=3$ で 0.84 倍) し、共通モードモデルを仮定する。
3. **GNN が距離とともにスケール。** $d=5$ で 33.4 倍 (95% CI: [12.3, 90.9])。4,033 パラメータの軽量さ (AlphaQubit 比 2,500 分の 1) で相関構造をモデルフリーに学習。 $\rho=0$ では vanilla に劣位 ($d=3$: 0.60 $\times$ 、 $d=5$: 0.75 $\times$) ——相関デコーダの限界を正直に報告する。
4. **残差減算は OOD でも GNN を上回る。** OOD $\rho=0.20$ で $d=5$: 残差減算 23.0 $\times$ vs GNN 9.9 $\times$ 、 $d=7$: 24.8 $\times$ vs 20.8 $\times$ 。共通モード型相関では、 ρ が訓練分布外であっても残差減算の原理が物理的に有効であり、ML 学習に依存しない。GNN の真の価値は、相関構造が非共通モード型の場合にモデルフリーで適応できる点にある。

残差減算と GNN は相補的である。共通モード型相関 ($\rho>0$) では OOD を含め残差減算が最強。相関構造が未知または非共通モード型るとき GNN が優位。実運用では ρ 推定器 (CUSUM 等) との組み合わせによるデコーダ自動切り替え—— $\rho=0$ では vanilla、 $\rho>0$ で共通モード型なら残差減算、構造不明なら GNN——が最適戦略である。

参考文献

- [1] K. Noh and C. Chamberland, “Low-overhead fault-tolerant quantum error correction with the surface-GKP code,” *Phys. Rev. X* **12**, 011058 (2022).
- [2] C. Gidney, “Stim: A fast stabilizer circuit simulator,” *Quantum* **5**, 497 (2021).
- [3] O. Higgott and C. Gidney, “Sparse Blossom: correcting a million errors per core second with minimum-weight matching,” *arXiv:2303.15933* (2023).
- [4] D. Gottesman, A. Kitaev, and J. Preskill, “Encoding a qubit in an oscillator,” *Phys. Rev. A* **64**, 012310 (2001).
- [5] R. W. J. Overwater, M. Babaie, and F. Sebastiano, “Neural-network decoders for quantum error correction using surface codes,” *IEEE Trans. Quantum Eng.* **3**, 3101319 (2022).
- [6] N. C. Menicucci, “Fault-tolerant measurement-based quantum computing with continuous-variable cluster states,” *Phys. Rev. Lett.* **112**, 120504 (2014).
- [7] B. Brock et al., “Fault tolerant decoding of QLDPC-GKP codes with circuit level soft information,” *arXiv:2505.06385* (2025).
- [8] B. W. Walshe et al., “Robust fault tolerance for continuous-variable cluster states with excess antisqueezing,” *Phys. Rev. A* **100**, 010301(R) (2019).

- [9] D. Tse and P. Viswanath, Fundamentals of Wireless Communications, Cambridge University Press (2005).
- [10] J. Bausch et al., “Learning high-accuracy error decoding for quantum processors,” Nature **635**, 834 (2024). [AlphaQubit]
- [11] V. Sivak et al., “Real-time quantum error correction beyond break-even,” Nature **616**, 50 (2023).
- [12] M. A. Tremblay et al., “Constant-overhead quantum error correction with thin planar connectivity,” Phys. Rev. Lett. **129**, 050504 (2022).
- [13] N. Shutty and C. Chamberland, “Efficient near-optimal decoding of the surface code through ensembling,” arXiv:2401.12434 (2024).
- [14] T. N. Kipf and M. Welling, “Semi-supervised classification with graph convolutional networks,” arXiv:1609.02907 (2017).
- [15] S. Wu and Y. Bar-Ness, “OFDM systems in the presence of phase noise: consequences and solutions,” IEEE Trans. Comms. **52**, 1988 (2004).
- [16] L. Skoric et al., “Parallel window decoding enables scalable fault tolerant quantum computation,” Nat. Comms. **14**, 7040 (2023).
- [17] S. Liyanage et al., “Scalable quantum error correction for surface codes using FPGA,” arXiv:2301.08419 (2023).

付録 A: スケール不変性の証明

soft-info MWPM の LLR 重みは

$$w_j(r_j, V) = ((\sqrt{\pi} - |r_j|)^2 - |r_j|^2) / (2V)$$

$V \rightarrow V'$ の変更に対し

$$w_j(r_j, V') = (V/V') \cdot w_j(r_j, V)$$

全エッジ j に同一のスカラー V/V' が乗じられるため

$$\arg \min_{\{M\}} \sum_{j \in M} w_j(V') = \arg \min_{\{M\}} (V/V') \sum_{j \in M} w_j(V) = \arg \min_{\{M\}} \sum_{j \in M} w_j(V)$$

$V/V' > 0$ であるから最適マッチングは不変。□

残差減算ではこの等式が破れる。 $r_j \rightarrow r'_j = r_j - r^-$ の変換は $|r'_j|$ が r^- に依存して非一様に変化するため、 $w_j(r'_j, V) \neq c \cdot w_j(r_j, V)$ となり、エッジ間の相対重みが変わる。

付録 B: p_{phys} の算出

GKP 変位ノイズの標準偏差 $\sigma = \sqrt{(V_{\text{eff}}/2)}$ に対し、変位誤り（最近接格子点の誤判定）確率は

$$p_{\text{phys}} = (1/2) \operatorname{erfc}(\sqrt{\pi} / (4 \sigma))$$

$\sigma_{\text{eff}} = 8.5 \text{ dB}$ の場合:

- 設計文書 (06_noise-budget.md) の全損失パス通過後の BS モデル計算
- $\eta = 0.914$ 、 $V_{sqz} = 0.0501$ 、 $V_{nl} = 0.010$ SNU
- $V_{eff} = 0.914 \times 0.0501 + 0.086 + 0.010 = 0.142 \approx 0.1417$ SNU
- $\sigma = \sqrt{(0.1417/2)} = 0.2662$
- $p_{phys} = \text{erfc}(\sqrt{\pi/(4 \times 0.2662)})/2 = 9.28 \times 10^{-3}$

本研究の全シミュレーションは $V_{eff} = 0.1417$ を使用。

付録 C: 実験パラメータと再現性

実験	d 値	n_train	n_test	ρ 条件	総ショット
V_{eff} 再校正	3,5,7	—	30K/30K/10K	6	170K
残差減算	3,5,7	—	30K/30K/10K	6	170K
Per- ρ GNN	3,5,7	5K/5K/3K	30K/30K/10K	6	~270K
Mixed- ρ GNN	3,5,7	5K/5K/3K	30K/30K/10K	7(+OOD)	~310K
総計					~920K

環境: Apple Silicon (MPS), PyTorch 2.5.1, torch_geometric, Stim 1.15.0, PyMatching 2.3.1。
総実行時間約 15 時間。seed=42 で全結果が再現可能。

DEM エッジ数について: Stim DEM の全エラーエントリ数 (d=3: 76、d=5: 418、d=7: 1,224) と、`extract_graph()` が 1-detector/2-detector エラーのみ抽出した実使用エッジ数 (d=3: 66、d=5: 334、d=7: 954) は異なる。差分は 0-detector (境界のみ) や 3-detector 以上のエラーエントリである。本研究の全シミュレーションは実使用エッジ数 (66/334/954) で実行されており、全エラーカウントは同一の `run_unified.py` スクリプト (seed=42) から生成され内部的に整合している。